

ローカルLLMでアニメキャラクターのロールプレイを崩さず維持する方法

エグゼクティブサマリー

結論から言う。あなたの症状の主因は「キャラ設定が足りない」ことではない。主因は、モデル固有のチャットテンプレートやロール仕様を外していること、長いキャラ設定をそのまま毎回流し込んで小型モデルの文脈処理を壊していること、長期会話のための状態圧縮と再注入が無いこと、そして推論スタック側のテンプレート不整合や thinking モードの扱いミスであることが多い。特に Gemma 1/2/3 の instruction-tuned 系は `system` ロールを正式にはサポートせず、初手の `user` に統合すべきだと Google が明記している。Qwen3 は thinking/non-thinking を切り替えられ、ロールプレイのような対話では `/no_think` や `enable_thinking: false` が有効な場面が多い。さらに、llama.cpp や量子化配布物、Ollama 側の chat template 問題が garbage token や支離滅裂化の直接原因になりうる。 ¹

安定したロールプレイは、長いプロフィールを貼る作業ではなく、**記憶管理**の設計問題として扱うべきだ。近年の役割演技系研究は、RoleLLM のように「役の知識抽出と注入」を分離し、Memory-Driven Role-Playing では persona knowledge を必要時に取り出すメモリとして扱い、LoCoMo や MemGPT 系は長期会話で long-context だけでは足りず、要約・検索・階層メモリが必要だと示している。実運用では、短い persona anchor、少数の例文、scene/relationship state、delta summary、必要箇所だけの canon retrieval を重ねる構成が最も壊れにくい。SillyTavern の Prompt/Author's Note と Open WebUI の Notes/Knowledge/RAG は、その運用形にかなり近い。 ²

モデル選定では、**小型で prompt-only 運用するなら Qwen3-1.7B が最有力、速度優先の基準線として Gemma 3 1B、日本語優先なら llm-jp 系、少し重くても破綻耐性を上げたいなら Ministral 3 3B や Qwen3 4B が実用候補になる**。Qwen3 は公式に creative writing・role-playing・multi-turn dialogues の強さをうたい、Qwen3 の最新小型系列ベンチでは 4B が fine-tune 後最上位、1.7B も有力だった。Gemma 3 1B は 32K 文脈・140超の言語対応で、Mac Studio M3 Ultra のコミュニティ計測では gemma3:1b が LM Studio で約 237 tok/s、Ollama で約 149 tok/s、Raspberry Pi 5 でも 18-22 tok/s の実測例がある。llm-jp 系は日本語データ比率が高く、日本語 MT Bench 系評価でも国産・日中英混在系モデルが競っている。ただし 1.8B 級の日本語特化モデルは 4K 文脈のものが多く、長期ロールプレイでは summary/retrieval を前提にすべきだ。 ³

English synthesis

The recurring failure is usually not “insufficient character description.” It is more often a combination of template mismatch, context overload, missing memory compression, and runtime/template bugs. Gemma 1/2/3 IT models officially do **not** support a separate `system` role; Qwen3 exposes a think/no-think switch that matters for roleplay latency and stability; and local stacks can break badly when chat templates are wrong. The most reliable pattern is to treat roleplay as a **memory architecture** problem: a short persona anchor, few-shot voice examples, rolling scene state, delta summaries, and selective retrieval. As a default small local model, Qwen3-1.7B is the best current balance; Gemma 3 1B remains a strong speed baseline with a critical prompt-format caveat; Japanese-first options like llm-jp are viable but more context-limited. ⁴

問題の正体と壊れ方

最初に押さえるべき事実は、小型ローカルLLMのロールプレイ崩壊はかなり再現性の高い失敗パターンを持つことだ。Japanese-RP-Bench の作成者は、日本語のロングターン対話を測るベンチマークが不足しており、その結果として「ロングターンの対話になると出力が崩壊するオープンモデルが多い」と明言している。LoCoMo も、平均 300 ターン・約 9K トークンの会話で、long-context や RAG を使っても人間との差が大きいことを示した。つまり、2〜3 ラリーで壊れるのは異常ではなく、未設計のままではむしろ普通だ。 ⁵

破綻の見え方	典型原因	何を直すか
数ターンで支離滅裂になる	長いキャラ設定を毎ターン流し込み、必要情報の抽出ができず、会話状態も圧縮していない	キャラ情報を短い anchor に圧縮し、scene state と delta summary を別管理にする。LoCoMo/MRPrompt 系の考え方に寄せる。 ⁶
system prompt を無視する	Gemma 1/2/3 IT では <code>system</code> ロール非対応	Gemma では system 指示を初手 user に統合する。Gemma 4 以降なら native system instructions を使う。 ⁷
突然 <code><think></code> 系や冗長な推論が混ざる、遅い	Qwen3 の thinking モードが有効	<code>/no_think</code> または <code>enable_thinking: false</code> を使う。RP では reasoning より会話安定性を優先する。 ⁸
garbage token、ループ、変な終了	chat template 不整合、配布物やランタイムのテンプレート不具合	公式テンプレート適用、runtime 更新、テンプレート検証を最優先する。Ollama/llama.cpp 周辺の既知問題を疑う。 ⁹
ユーザーの台詞や行動まで勝手に書く	“one speaker only” 契約がない、または group chat 扱いが曖昧	返答契約に「次の一発話だけ」「ユーザーの内面・台詞・行動を書かない」を明示し、例文でも守らせる。SillyTavern の docs も同系の注意をしている。 ¹⁰
プロンプトを変えても昔の口調が残る	履歴が main prompt より強い	旧履歴の編集、Author's Note / Post-History Instructions、または新規会話開始を使う。 ¹¹

SillyTavern の公式ドキュメントは、Main Prompt 変更の効果は既存の message history に強く制限されると説明している。つまり、途中から「もっとそのキャラらしく」と書き足しても、履歴に残った壊れた発話が強いつ学習例として残り続ける。ここを理解していないと、プロンプトを増やすほど悪くなる。 ¹²

日本語コミュニティ側でも、Ollama で詰まった Qwen3.6 を llama.cpp で直に動かしたら正常だった、つまり「モデル本体は健全で、Ollama の chat template / tool 仕様未成熟が原因だった」という実例が報告されている。これは niche だが重要だ。ロールプレイ崩壊はモデル能力不足だけでなく、**推論スタックの実装差**でも起きる。 ¹³

English synthesis

Long-turn roleplay failure is a known property of open models, not a rare edge case. Japanese-RP-Bench was created precisely because existing Japanese benchmarks were mostly short-turn and missed long-roleplay collapse; LoCoMo shows that even long-context and RAG do not fully solve long-term conversational memory. In practice, the first debugging step is to classify the failure: role-format

mismatch, context overflow, reasoning-mode leakage, template/runtime bugs, or speaker-boundary drift. Fixing the correct class matters more than adding more character lore. ¹⁴

横断調査で見えた設計原則

今回の横断収集では、公式ドキュメント、論文、ベンチマーク、GitHub issue、アプリのドキュメント、Reddit/LocalLLaMA 系スレッド、日本語の Zenn/Note 記事まで含めて見た。信頼度の高い順に使うべきソース群は次の通りだ。公式モデルカードと prompt-format docs は「そのモデルが何を前提としているか」を確定させる。次に、RoleLLM・CharacterEval・PingPong・Memory-Driven Role-Playing・LoCoMo・MemGPT のような研究が、評価軸とメモリ設計の基礎を与える。さらに、SillyTavern/Open WebUI docs や GitHub issue は、実際のローカル推論で何が壊れやすいかを教える。日本語圏では Japanese-RP-Bench がかなり有用で、Note のテンプレート不具合報告も実務価値が高い。 ¹⁵

優 先 度	ソース種別	役割	代表ソース
高	公式モデル docs / model cards	chat template、system role、supported languages、文脈長、推論オプションを確定する	Gemma prompt/system docs、Qwen3 model/speed docs、Llama 3.2 card、Phi-4-mini format、Mistral/Ministral cards ¹⁶
高	研究論文・ベンチマーク	何を評価すべきかを定義する	RoleLLM/RoleBench、CharacterEval、PingPong、MRBench/MRPrompt、LoCoMo、MemGPT ¹⁷
中	アプリ docs	実際のプロンプト組み立て位置と memory 注入手法を教える	SillyTavern Prompt/Author's Note、Open WebUI Notes/Knowledge/RAG ¹⁸
中	GitHub issues / discussions	実装バグ・テンプレート不整合・thinking 制御ミスを把握する	llama.cpp issue、Unsloth Gemma issue、OpenWhisper Qwen3 no_think、HF/Qwen discussions ¹⁹
中	日本語ベンチマーク / コミュニティ記事	日本語ロールプレイ特有の評価観点と実務バグを補う	Japanese-RP-Bench、Note の Qwen/Ollama テンプレート検証 ²⁰
低	一般フォーラム / community presets	popular/obscure な現場知見を拾う	LocalLLaMA roleplaying prompt threads、small-model presets、SillyTavern community assets ²¹

研究側の流れを一言で圧縮するとうなる。RoleLLM は “role profile construction → role-specific knowledge extraction → role prompting → role-conditioned tuning” という分解を示した。CharacterEval は会話・一貫性・魅力・人格など多面的評価を整備した。PingPong は multi-turn・dynamic・multi-model judge の実戦的評価を出した。Memory-Driven Role-Playing は Anchoring / Recalling / Bounding / Enacting の四段階で役割演技を捉え、MRPrompt によって小型モデルでも大きな改善が出ることを示した。つまり、**長文キャラ説明を丸投げする設計は、研究最前線の方と逆だ。** ²²

日本語ソースで重要なのは、Japanese-RP-Bench が「Roleplay Adherence」「Consistency」「Contextual Understanding」「Expressiveness」を中核観点に置き、ユーザー役モデルとアシスタント役モデルをぶつけ

て multi-turn 日本語ロールプレイを評価している点だ。これは実運用の評価設計にかなりそのまま使える。

23

English synthesis

The cross-search converges on one design principle: roleplay quality is not mainly a “longer persona prompt” problem. It is a structured retrieval and evaluation problem. Official model docs tell you the interface contract; papers tell you what to measure; app docs and GitHub issues tell you where real local pipelines break. For Japanese specifically, Japanese-RP-Bench is one of the most useful practical references because it targets multi-turn roleplay instead of short generic chat. 24

モデル別のプロンプト設計と候補比較

まず、Gemma と Qwen だけでなく、少なくとも Llama、Phi、Mistral/Ministral、llm-jp まで含めて設計差分を見るべきだ。ロールプレイの成否はモデル能力よりも正しい入力フォーマットに乗せているかで大きく変わる。Gemma 3 系の system-role 非対応は最大の落とし穴で、Qwen3 の think/no-think は最大の調整点だ。Mistral 系は system prompt 遵守が強めで、Phi はフォーマットがかなり明示的、llm-jp は日本語データ寄りだが小文脈なことが多い。 25

モデル	ロールプレイ向けの入力設計で重要な点	日本語・文脈・速度に関する実務判断
Gemma 3 1B	Gemma 1/2/3 IT は system ロール非対応。system 級の指示は初手 user に統合する必要がある。1B は 32K context、Gemma 3 全体は 140超言語対応。 26	速度基準線として有力。コミュニティ計測では Mac Studio M3 Ultra で約 149–237 tok/s、Raspberry Pi 5 で 18–22 tok/s の報告がある。ただし prompt-format を間違えると一気に壊れる。 27
Qwen3 1.7B	thinking / non-thinking を一つのモデルで切り替え可能。creative writing・role-playing・multi-turn dialogues の強さを公式に訴求。RP はまず /no_think で始めるべき。 28	小型帯で最有力。1.7B は 0.6B より遅いが、役割保持余力は大きい。Qwen の公式 speed doc でも 0.6B→1.7B→4B の順に重くなる。 29
Qwen3 0.6B	Qwen3 系の設計は同じ。prompt-only では限界が早いので、役の種類を絞るか LoRA 前提で使うのが妥当。 30	Gemma 3 1B に近いが、それ以上の速度帯が見込める最有力候補。ただし RP の安定性は 1.7B より落ちやすい。distil labs でも 0.6B は tunability が高い。 31
Llama 3.2 1B	標準的な system / user / assistant 会話が可能で、system prompt の例も明示されている。128K context。 32	かなり速い。OnePlus 12 上の公式 ExecuTorch 計測で 1B BF16 が 19.2 tok/s、SpinQuant で 50.2 tok/s。fine-tuning での伸びも大きい。ただし公式 supported languages に日本語は含まれていない。 33
Phi-4-mini 3.8B	chat format が明示的で、< system >...< user >...< assistant > を前提にしている。128K context。高い instruction adherence。 34	純粋な“キャラ芝居”専用より、judge / summarizer / state extractor 役で強い。3.8B なので Gemma 3 1B より明確に重い。日本語は multilingual support だが用途別検証が必要。 35

モデル	ロールプレイ向けの入力設計で重要な点	日本語・文脈・速度に関する実務判断
Ministral 3 3B	日本語を含む多言語、system prompt 強め、agentic 機能あり。FP8 instruct。 ³⁶	8GB VRAM に収まりやすい 3B 級で、Gemma 1B 帯よりは遅いが、system 指示の安定性は魅力。日本語ロールプレイの“少し重いのが壊れにくい”枠。 ³⁶
Mistral Small 3.1 24B	24言語に日本語を含み、128K context、system prompt adherence を明示。基本 instruct template も公開。 ³⁷	速度は Gemma 3 1B に全く準じないが、prompt-only での安定度を優先するなら質的候補。RP 崩壊を latency で買い戻すタイプ。Mistral Small 3.2 は長く反復的なプロンプトで infinite generations を約 2x 減らしたと案内している。 ³⁸
llm-jp 3 1.8B instruct / 3.1 系	日本語データ比率が高く、標準 chat template を使う。llm-jp 3 1.8B instruct は context 4K。3.1 系は instruction pre-training と DPO が追加されている。 ³⁹	日本語優先なら有力だが、4K 級文脈は長編ロールプレイに不利。summary/retrieval が必須。 <code>llm-jp-3.1-1.8b-instruct4</code> は新しいが、公開ビュー上では 1.8B 行の仕様確認がやや煩雑。 ³⁹

非推奨候補もはっきりさせる。**PLaMo 2 1B** は英日 1B で面白いが、公式に「chat dialog 用に instruction-tuned されていない」と書かれているので、そのままのロールプレイ用途には向かない。**LINE の japanese-large-lm-1.7b-instruction-sft** は日本語 1.7B instruct として歴史的価値はあるが、現行の小型モデル群と比べると古く、長文脈・マルチターン耐性・最近の alignment 面で優位性を主張しづらい。 ⁴⁰


小型モデルの prompt engineering 事例としては、SillyTavern が「Main Prompt は会話全体の一般ルール」「例示は example messages」「その場の強い補正は Author's Note を末尾近くへ」という分担を採っている。これを各モデルのチャットテンプレートに合わせて再実装するのが最も堅い。Gemma 3 系だけは system prompt 欄に長文を入れる設計をやめ、“**初手 user に役割規約を畳み込む**”のが本筋だ。 ⁴¹

English synthesis

For roleplay, the most important difference across local models is not “benchmark rank” but **prompt interface semantics**. Gemma 3 is fast but requires user-role anchoring instead of a true system message. Qwen3 is the best small-model family for roleplay because it explicitly targets creative writing and multi-turn dialogue, and because you can disable thinking. Llama 3.2 1B is highly tunable and fast but weaker as a Japanese-default option. Japanese-first families like llm-jp are attractive for language quality but need aggressive memory management because of shorter context. ⁴²

会話維持とキャラクター維持の実装

ロールプレイを壊さない最小構成は、一枚の巨大キャラシートではなく、複数の小さな層で持つことだ。SillyTavern は prompt の組み立て位置を変えられ、Author's Note を履歴末尾近くへ挿入できる。Open WebUI は Notes に full-fidelity context を置き、Knowledge/RAG で検索注入し、8K 文脈なら chunk size 1000・overlap 100・Top K 3-5 を推奨している。MemGPT はこれをさらに進めて main context と外部メモリの階層設計を示した。これらを合成すると、ローカルRPの実装パターンはかなり明確になる。 ⁴³



この構成で重要なのは、**固定アンカー**と**可変状態**を分けることだ。固定アンカーには、キャラの核だけを入れる。可変状態には、現在の場面、関係性、最近の出来事、会話で新たに確定した事実だけを入れる。MRPrompt が示す Anchoring / Recalling / Bounding / Enacting の分解は、そのままプロンプト設計に対応する。Anchoring は固定アンカー、Recalling は retrieval、Bounding はユーザーの台詞を書かない等の境界条件、Enacting は実際の口調生成だ。 44

層	入れるもの	目安	更新タイミング
Persona anchor	身元、価値観、話し方、禁則、会話契約	300–900 tokens 程度の圧縮版が目安。長文略伝は入れない	ほぼ固定
Example utterances	口調を示す短い例を 2–6 本	説明文より例文優先	キャラ変更時のみ
Scene state	現在地、目的、感情温度、相手との距離、未解決事項	100–300 tokens	毎ターン更新
Recent turns	直近 4–8 発話程度	モデルサイズで調整	毎ターン更新
Delta summary	新しく確定した事実と進行だけ	「差分要約」にする	2–4 ターンごと
Canon retrieval	今の場面に必要な設定だけ	Top K を小さく保つ	必要時のみ

この表は、MemGPT の階層メモリ、Open WebUI の context budget 指針、SillyTavern の Prompt/Author's Note、Japanese-RP-Bench と MRBench の評価発想を実装に落としたものだ。特に Open WebUI のドキュ

メントは、8K 文脈モデルで RAG を雑に入れると会話履歴が削られて follow-up が切れると警告している。小型モデルほど retrieval を「多ければよい」と考えるのは誤りだ。 ⁴⁵

補助ツールも有効だ。Open WebUI の Notes/Knowledge は full-context 注入と agentic retrieval を提供する。コミュニティには、会話の narrative delta だけを要約する Summaryception や、人物・関係・ムード・緊張・クエスト等を抽出する ScenePulse のような拡張もある。これらは本質的に「外部状態管理」であり、小型ローカルモデルの弱点を補う方向として合理的だ。 ⁴⁶

English synthesis

A robust local RP stack should separate **persistent persona** from **dynamic scene state**. Keep the persona anchor small and stable; keep scene state and delta summaries short and refreshed; keep retrieval selective. This matches both research trends in memory-driven roleplay and the practical architecture exposed by SillyTavern, Open WebUI, and MemGPT-like systems. The main anti-pattern is dumping full canon and full history every turn. ⁴⁷

評価指標とテストスイート

評価は「なんとなくそれっぽい」で済ませるべきではない。CharacterEval は 4 次元 13 指標、Japanese-RP-Bench は Roleplay Adherence / Consistency / Contextual Understanding / Expressiveness、PingPong は character consistency / entertainment value / language fluency、MRBench は Anchoring / Recalling / Bounding / Enacting という分解を提示している。これらをそのままローカル評価 harness に変換すればよい。 ⁴⁸

指標	何を見るか	研究・実務上の由来	ローカルでの実装法
Role adherence	そのキャラとして返答しているか	Japanese-RP-Bench、CharacterEval、PingPong ⁴⁹	judge モデルにキャラ設定と応答を渡し、5 段階採点する
Consistency	長い会話で矛盾しないか	Japanese-RP-Bench、CharacterEval ⁵⁰	過去 state と応答を比較し、属性・関係・口調の矛盾を数える
Context recall	直前・数ターン前・前セッションの事実を覚えているか	LoCoMo、MRBench ⁵¹	hidden probe 質問を数ターンおきに差し込む
Bounding	ユーザーの台詞や内面まで勝手に書かないか	MRBench、SillyTavern docs ⁵²	speaker-leak 率を測る
Expressiveness	感情・トーン・台詞の表現力	Japanese-RP-Bench、CharacterEval ⁵⁰	judge で採点し、例文との差も観察する
Fluency / coherence	日本語として自然で会話が読めるか	PingPong、CharacterEval ⁵³	judge + 人手 A/B 比較を併用する
Recovery success	破綻後に correction prompt で戻せるか	MRBench の staged ability を実務拡張したもの ⁵⁴	drift 注入後に recovery prompt を当て、2 ターン以内復帰率を測る

実際のテストスイートは、**短い静的ベンチ**ではなく、**場面差分を含む multi-turn**にすべきだ。PingPong は dynamic multi-turn と multi-model judge が human annotation とよく相関すると報告している。

Japanese-RP-Bench もユーザー役モデルとアシスタント役モデルを分けて対話を転がす設計を採っている。したがって、ローカル評価も「設定付き 12-20 ターン会話」「途中で hidden probes」「最後に judge」「100 会話分だけ人手 A/B 校正」が妥当だ。 55

最低限の回し方としては、キャラ 8 体、シーン 6 種、温度 2 条件、合計 96 エピソード程度から始めればよい。各エピソードで turn 4 / 8 / 12 に hidden probe を入れ、turn 12 で総合 judge を行う。破綻率が高いモデルでは、scene change を入れた瞬間と relationship change を入れた瞬間のスコアが急落しやすい。これは MREval の Recalling / Bounding / Enacting を分けてみると原因が切り分けやすい。 56

English synthesis

Do not evaluate RP with one-turn prompts. Use multi-turn scene tests with hidden probes, a separate judge model, and a small human calibration set. The most useful metric bundle is: role adherence, consistency, context recall, bounding, expressiveness, fluency, and recovery success. This combines the best parts of CharacterEval, Japanese-RP-Bench, PingPong, MREval, and LoCoMo-style memory stress tests. 57

実践的改善手順とサンプルプロンプト集

改善手順は、一気に全部やるより、壊れ方を一つずつ潰す方が速い。順番は固定した方がよい。**最初にテンプレート、次にキャラ情報の圧縮、次に状態管理、最後に tuning**だ。RoleLLM と distil labs の結果を合わせて読むと、prompt-only の改善余地は大きい、合わせて small-model fine-tuning の費用対効果も非常に高い。小さいモデルほど tunability が高い傾向も出ている。 58

まずやるべき手順は次だ。

テンプレート整合性を確認する。Gemma 3 なら system を捨てて初手 user に入れる。Qwen3 は `/no_think` から始める。llama.cpp / Ollama / LM Studio / Open WebUI のどれを使うにせよ、**適用された最終 prompt** を見て、期待した role/turn token になっているか確認する。ここで壊れていれば、それ以降は全部無駄だ。 59

次に、長いキャラ説明を捨てて、以下のような **voice/style/content 分離テンプレート** にする。これは RoleLLM の role profile extraction、MRPrompt の structured retrieval、SillyTavern の example message 重視を実務向けに縮約した形だ。 60

```
character_anchor:
  identity:
    name: ""
    age_band: ""
    role_in_story: ""
  core_values:
    _ ""
    _ ""
  motives:
    short_term: ""
    long_term: ""
  speech_style:
    sentence_length: "short / medium / long"
    formality: "plain / polite / mixed"
  signature_features:
```



```

- ""
- ""
forbidden_features:
- "Do not switch to generic assistant tone"
- "Do not narrate the user's dialogue or inner thoughts"
emotional_baseline:
default_tone: ""
triggers:
anger: ""
embarrassment: ""
affection: ""
knowledge_bounds:
knows:
- ""
does_not_know:
- ""
response_contract:
- "Write only the character's next reply."
- "Stay in the current scene unless the user changes it."
- "If unsure, ask an in-character question instead of inventing canon."

```

system role を持つモデル向けの最小テンプレートは、次のように短くするのがよい。説明文を増やしすぎるより、**役の核 + 会話契約 + 例文**に寄せた方が小型モデルでは効く。SillyTavern の docs も、何をしてほしいかより、どう書いてほしいかを示す方が効くと説明している。 ¹²

```

System:
You are participating in a fictional roleplay chat.
Stay in character at all times.

Character anchor:
{{CHARACTER_ANCHOR}}

Scene state:
{{SCENE_STATE}}

Recent facts:
{{DELTA_SUMMARY}}

Rules:
- Write only {{char}}'s next reply.
- Never write {{user}}'s dialogue, actions, or thoughts.
- Prefer one clear reply over exposition.
- If a canon fact is missing, ask in-character or stay ambiguous.
- Preserve speech style before adding new plot details.

Example style snippets:
{{STYLE_EXAMPLES}}

```

Gemma 3 向けには、同じ内容を **初手 user** に畳み込む。これが重要だ。Gemma 1/2/3 IT に system role を入れ続ける設計は誤りである。 ⁶¹

User:
We are doing a fictional roleplay chat. Follow these instructions for the entire conversation.

Character anchor:
{{CHARACTER_ANCHOR}}

Scene state:
{{SCENE_STATE}}

Rules:

- Write only {{char}}'s next reply.
- Never write my dialogue, actions, or thoughts.
- Stay in character.
- Keep replies grounded in the current scene.
- Ask an in-character question if information is missing.

Now reply to this in character:
{{FIRST_USER_UTTERANCE}}

会話維持用には、**差分要約プロンプト**を分けて持つべきだ。Summaryception が“narrative delta”だけを更新するのは正しい発想で、Open WebUI の Notes/Knowledge と組み合わせやすい。 62

Summarizer instruction:
Read the last 2-4 turns and update the running summary.

Keep only:

- new facts that became true
- relationship changes
- scene/location changes
- unresolved goals or promises
- emotional shifts relevant to future replies

Do not keep:

- repeated phrasing
- decorative prose
- facts already in the summary

Output JSON:

```
{
  "new_facts": [],
  "relationship_updates": [],
  "scene_updates": [],
  "open_loops": [],
  "tone_shift": ""
}
```

破綻したときの recovery prompt も常備すべきだ。これは「全会話をやり直す」より速い。MRBench の Bounding / Enacting の発想に沿って、**どこを外したか**だけ戻す。 54

Recovery note:
Reset to the character anchor and current scene state.

You drifted in one or more ways:

- out-of-character tone
- wrote the user's side
- contradicted prior facts
- generic assistant phrasing

For the next reply only:

- re-align with the character anchor
- preserve the current scene
- write one in-character reply
- do not apologize unless the character would apologize

ミニ例も示す。悪い構成では、キャラ設定 2,500 tokens を system に貼り、履歴も全投入し、scene state を持たない。その結果、3 ターン目で「百科事典モード」か「generic assistant モード」になる。良い構成では、anchor を 500–800 tokens に圧縮し、scene state を 100 tokens 前後で持ち、直近 6 発話と delta summary だけを見せる。すると発話スタイルと関係の継続がかなり保ちやすい。これは研究上の memory-driven view と、SillyTavern/Open WebUI の prompt layering の両方と整合する。 ⁶³

English synthesis

The practical sequence is: verify template semantics, compress the character card, add scene state, add delta summaries, add selective retrieval, and only then consider fine-tuning. Keep prompts short and layered. For Gemma 3, move persistent instructions into the first user turn. For Qwen3, start with no-think mode. Recovery prompts should target the exact drift mode instead of restarting the whole conversation. ⁶⁴

日本語運用に向く推奨モデル

ここは断言する。「日本語が普通に喋れて、Gemma 3 1B に準ずる速度かそれ以上、かつロールプレイでも破綻しにくい」という条件を同時に高い水準で満たすモデルは多くない。ハードウェア条件が未指定なので、速度比較は vendor 公式と一部コミュニティ計測が混ざる。したがって、以下は **同一ハード同条件の絶対比較ではなく、実務上の推奨順位**として読むべきだ。 ⁶⁵

推奨順位	モデル	推奨理由	主なトレードオフ
最有力	Qwen3-1.7B	role-playing ・ creative writing ・ multi-turn dialogue を公式に強調。think/no-think 制御があり、no-think なら RP 用の latency と安定性が上げやすい。小型帯で最も無難。 ²⁸	Gemma 3 1B よりは通常遅い。日本語は強いが、同一条件の速度指標は要ローカル実測。
速度基準線	Gemma 3 1B	1B で 32K、140超言語、端末向け運用実績が多い。Mac/Pi の速度報告があり、体感速度の基準線として優秀。 ⁶⁶	最大の欠点は system role 非対応。ここを外すと簡単に崩れる。

推奨順位	モデル	推奨理由	主なトレードオフ
最速寄りの代替	Qwen3-0.6B	速度帯は Gemma 3 1B に近いが上振れ候補。公式 small-model ベンチでも tunability が高い。限定キャラや LoRA 前提なら面白い。 ³¹	prompt-only の長期 RP は 1.7B より脆い。キャラ幅を絞るべき。
日本語優先	llm-jp 3.1-1.8B 系 / llm-jp 3 1.8B instruct	日本語データ比率が高く、日本語運用の自然さを重視するなら有力。国産系の強みがある。 ³⁹	4K 文脈級が足を引っ張る。summary/retrieval なしの長期 RP は厳しい。
高速・高 tunability	Llama 3.2 1B	system prompt が素直、公式 on-device 速度も高い。fine-tuning では最も伸びやすい部類。 ⁶⁷	日本語は公式 supported languages に含まれない。日本語 RP の default 候補にはしにくい。
少し重いが安定寄り	Ministral 3 3B	日本語を含む多言語、system prompt 強め、8GB VRAM 級でも視野。RP の壊れにくさを latency で買える。 ³⁶	Gemma 3 1B より明確に遅い。
品質重視	Qwen3 4B / Mistral Small 3.1 24B	prompt-only の質と安定性を上げたいなら、このクラスで一段良くなる。Qwen3 4B は fine-tuned 成績でも優勢。Mistral Small 3.1 は system adherence と多言語が強い。 ⁶⁸	Gemma 3 1B に準ずる速度ではない。

「Gemma 3 1B と同等以上の速度」を真面目に守るなら、実際の候補は **Qwen3-0.6B**、**Gemma 3 1B**、**Llama 3.2 1B** あたりまでに絞られる。だが、この中で日本語と roleplay の両方を総合すると、**速度だけなら Qwen3-0.6B / Gemma 3 1B**、**総合バランスなら Qwen3-1.7B**、**日語特化なら llm-jp 系** という整理になる。3B を超えると、多くの環境で Gemma 3 1B に準ずる速度とは言いにくい。これはパラメータ規模、公式 speed docs、オンデバイス計測からの素直な推論だ。 ⁶⁹

fine-tuning を許容するなら話は変わる。distil labs の 12 モデル比較では、Qwen3-4B が fine-tuned 後の総合首位、Llama-3.2-1B が tunability 首位で、Qwen3-0.6B も小型の割に大きく伸びている。RoleLLM も role-conditioned tuning で role-playing 能力を明確に改善した。したがって、**prompt-only で限界を感じたら、1-4B クラスに LoRA を薄く当てる** 方が、さらに長いプロンプトを盛るより合理的だ。 ⁷⁰

最後に watchlist を一つだけ挙げる。Gemma 4 は native system instructions、function calling、長文脈、140+ languages を前面に出しており、Gemma 3 系の最大の欠点だった “system role 非対応” を解消している。E2B/E4B は edge 向けで魅力的だが、現時点では Gemma 3 1B 基準の same-class RP 実績はまだ蓄積中なので、即断の主力推奨にはしない。 ⁷¹

English synthesis

If you need Japanese plus near-Gemma 3 1B runtime, the realistic shortlist is small: Qwen3-0.6B, Gemma 3 1B, Qwen3-1.7B, and Japanese-focused 1.8B-class models. My default pick for prompt-only roleplay is **Qwen3-1.7B**. My speed baseline is **Gemma 3 1B**, but only if you respect its no-system-role requirement. For Japanese-first deployments, **llm-jp** is compelling but needs aggressive summary/retrieval because of shorter context. If you can afford more latency, **Ministral 3 3B** or **Qwen3 4B** is a better landing zone. Fine-

tuning changes the ranking again: small models, especially Llama 3.2 1B and Qwen3 0.6B/4B, respond well to it. 72

1 4 7 15 16 25 26 42 59 61 64 <https://ai.google.dev/gemma/docs/core/prompt-structure>
<https://ai.google.dev/gemma/docs/core/prompt-structure>

2 17 22 24 58 60 <https://arxiv.org/abs/2310.00746>
<https://arxiv.org/abs/2310.00746>

3 28 30 72 <https://huggingface.co/Qwen/Qwen3-1.7B>
<https://huggingface.co/Qwen/Qwen3-1.7B>

5 14 20 23 49 50 https://zenn.dev/aratako_lm/articles/42ad1a6ac9da45
https://zenn.dev/aratako_lm/articles/42ad1a6ac9da45

6 44 47 52 54 56 63 <https://arxiv.org/abs/2603.19313>
<https://arxiv.org/abs/2603.19313>

8 <https://qwenlm.github.io/blog/qwen3/>
<https://qwenlm.github.io/blog/qwen3/>

9 19 <https://github.com/unslothai/unsloth/issues/2744>
<https://github.com/unslothai/unsloth/issues/2744>

10 11 12 18 41 43 <https://docs.sillytavern.app/usage/prompts/>
<https://docs.sillytavern.app/usage/prompts/>

13 <https://note.com/zephel01/n/ncf14ddd3a335>
<https://note.com/zephel01/n/ncf14ddd3a335>

21 https://www.reddit.com/r/LocalLLaMA/comments/1aiz6zu/roleplaying_system_prompts/
https://www.reddit.com/r/LocalLLaMA/comments/1aiz6zu/roleplaying_system_prompts/

27 <https://medium.com/google-cloud/gemma-3-performance-tokens-per-second-in-lm-studio-vs-ollama-mac-studio-m3-ultra-7e1af75438e4>
<https://medium.com/google-cloud/gemma-3-performance-tokens-per-second-in-lm-studio-vs-ollama-mac-studio-m3-ultra-7e1af75438e4>

29 31 65 69 https://qwen.readthedocs.io/en/latest/getting_started/speed_benchmark.html
https://qwen.readthedocs.io/en/latest/getting_started/speed_benchmark.html

32 33 67 <https://huggingface.co/meta-llama/Llama-3.2-1B-Instruct>
<https://huggingface.co/meta-llama/Llama-3.2-1B-Instruct>

34 35 <https://huggingface.co/microsoft/Phi-4-mini-instruct>
<https://huggingface.co/microsoft/Phi-4-mini-instruct>

36 <https://huggingface.co/mistralai/Mistral-3-3B-Instruct-2512>
<https://huggingface.co/mistralai/Mistral-3-3B-Instruct-2512>

37 38 <https://huggingface.co/mistralai/Mistral-Small-3.1-24B-Instruct-2503>
<https://huggingface.co/mistralai/Mistral-Small-3.1-24B-Instruct-2503>

39 <https://huggingface.co/llm-jp/llm-jp-3-1.8b-instruct>
<https://huggingface.co/llm-jp/llm-jp-3-1.8b-instruct>

40 <https://huggingface.co/pfnet/plamo-2-1b>
<https://huggingface.co/pfnet/plamo-2-1b>

45 <https://arxiv.org/abs/2310.08560>

<https://arxiv.org/abs/2310.08560>

46 <https://docs.openwebui.com/features/>

<https://docs.openwebui.com/features/>

48 <https://arxiv.org/abs/2401.01275>

<https://arxiv.org/abs/2401.01275>

51 <https://arxiv.org/abs/2402.17753>

<https://arxiv.org/abs/2402.17753>

53 55 <https://arxiv.org/html/2409.06820v4>

<https://arxiv.org/html/2409.06820v4>

57 <https://aclanthology.org/2024.acl-long.638/>

<https://aclanthology.org/2024.acl-long.638/>

62 <https://github.com/Lodactio/Extension-Summaryception>

<https://github.com/Lodactio/Extension-Summaryception>

66 https://ai.google.dev/gemma/docs/core/model_card_3

https://ai.google.dev/gemma/docs/core/model_card_3

68 70 <https://www.distillabs.ai/blog/we-benchmarked-12-small-language-models-across-8-tasks-to-find-the-best-base-model-for-fine-tuning/>

<https://www.distillabs.ai/blog/we-benchmarked-12-small-language-models-across-8-tasks-to-find-the-best-base-model-for-fine-tuning/>

71 <https://blog.google/innovation-and-ai/technology/developers-tools/gemma-4/>

<https://blog.google/innovation-and-ai/technology/developers-tools/gemma-4/>