

ローカルLLMでアニメキャラクターのロールプレイを崩壊させないための実践研究報告

エグゼクティブサマリー

結論から言います。あなたの症状は、主に「モデル能力不足」だけではなく、「情報の置き方が悪い」「モデル固有のチャットテンプレートを守っていない」「会話メモリとキャラクター設定を分離していない」「サンプリングやバックエンド設定がロールプレイ用途に合っていない」の複合問題です。特に 0.5B~1.5B 級のローカルLLMでは、巨大なキャラ設定を一度に恒常コンテキストへ押し込み、さらに会話履歴・世界設定・話し方・感情遷移・プロット進行まで同時管理させる設計は壊れやすいです。研究側でも persona conditioning の必要性は古くから指摘されており、近年の role-play 研究では「役割プロファイル」「役知識注入」「多面的評価」が別々に扱われています。SillyTavern 系の実務知見でも、短い恒常アンカー、後段指示、要約、Lorebook/World Info 注入の分離が中核です。 ①

最重要の実務ルールは四つです。第一に、Gemma と Qwen はそれぞれ学習時に想定された会話フォーマットがあり、Qwen は「指定された chat template を使うことが crucial」と公式に書いています。第二に、キャラの核情報は短く恒常化し、可変情報は Post-History Instructions や Author's Note に寄せます。第三に、会話要約と世界知識は別管理にします。第四に、反復や思考漏れはモデル設定で止めます。Qwen3 は反復が強い場合 `presence_penalty=1.5` を推奨しており、llama.cpp は repeat penalty と DRY repetition penalty を公式に提供しています。 ②

モデル選定では、「Gemma 3 1B に近いかそれ以上の速度感」と「日本語でのRP安定性」を両立した候補として、**Qwen3-0.6B**、**Sarashina2.2-0.5B / 1B**、**Qwen2.5-1.5B-Instruct**、**TinySwallow-1.5B-Instruct**、**RakutenAI-2.0-mini-instruct** が有力です。速度最優先なら Qwen3-0.6B と Sarashina2.2-0.5B、日本語重視なら Sarashina2.2-1B、総合安定性なら Qwen2.5-1.5B または TinySwallow-1.5B が有望です。Gemma 3 1B は 128K・140+言語対応という強みはありますが、今回収集した公式ソース群では日本語ロールプレイ向けの明示的ベンチマークは見当たりませんでした。Qwen3 は公式に creative writing・role-playing・multi-turn dialogues での改善を掲げています。 ③

この報告は、一次・準一次ソースを優先して、ACL/ArXiv 論文、Google/Qwen の公式ドキュメント、Hugging Face の公式モデルカード、SillyTavern 公式ドキュメント、GitHub Issues/Discussions、Reddit のコミュニティスレッド、日本語 Note/技術ブログ・日本語Wiki を横断して整理しています。Discord は公開索引性が低く直接引用しにくいいため、検索可能な公開ソースを中心に扱っています。 ④

English summary: Early roleplay breakdown in small local LLMs is usually a systems design problem, not just a model problem. The robust pattern is: use the model's native chat template, keep a short persistent persona anchor, move volatile scene constraints close to the end of the prompt, separate episodic memory from lore, and tune decoding to suppress repetition and meta leakage. For fast Japanese-capable local use, the strongest current small-model candidates are Qwen3-0.6B, Sarashina2.2-0.5B/1B, Qwen2.5-1.5B, TinySwallow-1.5B, and RakutenAI-2.0-mini-instruct. ⑤

なぜ数ターンで壊れるのか

数ターンで崩れる最大理由は、**キャラクター情報の粒度が細かすぎるのに、優先順位が付いていない**からです。研究系では persona を会話へ条件付けること自体に意味があるとされ、Persona-Chat は「一貫した

personality がない」ことを対話モデルの問題として扱いました。一方で SillyTavern の設計上、毎回必ず送られる恒常トークンは Character Name / Description / Personality / Scenario などに限られ、**First message は初回のみ、Example messages はコンテキストが埋まると落ちる**ため、あなたが例文に頼ってキャラの口調を学習させても、会話が進むとその支え自体が消えます。 6

もう一つの大きな原因は、**モデル固有テンプレートの不一致**です。Gemma の instruction-tuned モデルは、会話の roles と turns を明示する専用 formatter を前提に学習されています。Qwen も chat template を正しく使うことが generation control にとって重要だと明記しています。つまり、Gemma や Qwen をローカル UI や llama.cpp 経由で使うとき、見た目上は同じ「system / user / assistant」会話でも、実際に backend に渡るテンプレートがズレるだけで追従性が明確に悪化します。 7

さらに、**会話メモリとキャラクター性が混ざっていると壊れます**。World Info / Lorebook はキーワード発火で動的に入る仕組みで、内容欄だけが実際にコンテキストへ入り、タイトルやキーワード自体は入りません。つまり、Lorebook 項目が「単独で読んで意味が通る短い事実」になっていないと、モデルは参照できません。要約も万能ではなく、コミュニティ実務では「手動要約が一番信頼できる」という意見が強く、自動 summarizer は誰が何をしたかを混同すると逆効果になり得ます。 8

最後に、**反復・暴走・急な支離滅裂化は、サンプリングとバックエンド実装の問題でも起こる**ことを押さえるべきです。llama.cpp は repeat-penalty、repeat-last-n、DRY sampling を公式に提供しており、Qwen3 のモデルカードは endless repetitions に対して presence_penalty=1.5 を案内しています。また、歴史的な llama.cpp の context overflow 周りでは n_keep と context swapping によって先頭プロンプトの保持が弱く見えるケースが議論されてきました。つまり、「**モデルがバカ**」ではなく「**設定がキャラアンカーを殺している**」場合があります。 9

破綻パターン	支配的な原因	一番効く対策	根拠
口調がすぐ普通のアシスタントに戻る	例文や最初の挨拶に依存し、恒常トークンにキャラ核がない	キャラ核を Description / Personality / Scenario に短く固定	10
ユーザーの行動や心情まで勝手に書く	turn-taking ルールが弱い	PHI/AN に「ユーザーの発話・行動・内心を書かない」を明示	11
数ターン後に設定忘れ	非恒常の Example messages が脱落 / 要約不在	重要事実を恒常アンカーへ移し、要約を別管理	12
lore を読まない	Lorebook 項目が standalone でない / 発火が雑	standalone 化、短文化、発火語整理	13
同じ言い回しをループ	反復抑制不足、返答長すぎ	返答長上限、repeat penalty / DRY / presence penalty	14
長い会話の後に急に壊れる	context overflow と anchor 劣化	n_keep 見直し、古い履歴の要約・退避、章分け	15

English summary: Small models usually fail because persona, memory, and scene control are packed into the same shrinking context. Example dialogues often fall out of context, lore entries may not be standalone, and repetition can be backend-induced. Treat template alignment, permanent anchor design, and context overflow handling as first-class engineering tasks. 16

効くプロンプト設計パターン

まず、「詳しい設定をたくさん入れるほど良い」は誤りです。小型モデルに効くのは、長い人物事典ではなく、短く優先順位が明確なアンカーです。Qwen2.5 は system prompt の多様性への耐性向上を明示しており、RoleLLM は「Role Profile Construction」「Context-Instruct」「Role-specific knowledge injection」を分けています。ST の設計でも Main Prompt、Post-History Instructions、World Info を別レイヤで扱います。したがって、キャラRP用プロンプトは少なくとも **役割核 / 発話様式 / 禁止事項 / 現在シーン** の四層に分けるべきです。 ¹⁷

パターン	何を短く固定するか	何を可変にするか	使う場所	向くモデル	根拠
最小アンカー型	名前、自己認識、話し方、禁止事項	現在シーン	System / Main Prompt	Gemma, Qwen, Sarashina	¹⁸
後段拘束型	返答長、ユーザー不干涉、次ターン方針	現在の会話ルール	Post-History / PHI	ST運用全般	¹⁹
近接補強型	今この場面だけの感情・目的	シーン固有の制約	Author's Note 深度浅め	小型モデル全般	²⁰
動的 lore 注入型	世界設定・人物関係・固有名詞	発火語で必要時のみ	World Info / Lorebook	長期会話	¹³
Few-shot 口調固定型	2〜4本の短い例文	会話で伸べる履歴	Example messages	2B以上で特に有効	²¹
非思考即応型	キャラ返答のみ	推論過程は切る	Qwen3 <code>enable_thinking=False</code> 相当	低遅延RP	²²

以下は、収集した原則を踏まえて組み直した**小型ローカルLLM向けの汎用テンプレート**です。これは公式テンプレートそのものではなく、Gemma/Qwen/ST/RoleLLM/Persona 系の原則を合わせた実務用の合成テンプレートです。 ²³

[System / Main Prompt]

あなたは {キャラ名} である。

AIとして振る舞わない。説明役にもならない。{キャラ名} としてのみ返答する。

常に日本語で話す。

守ること：

- ユーザーの台詞、行動、内心を書かない
- メタ発言をしない
- 設定と現在シーンに矛盾しない
- 一回の返答では場面を一步だけ進める
- 口調は以下を維持する：
 - 一人称：{一人称}
 - 二人称：{二人称}
 - 語尾/口癖：{3〜8個}

- 敬語レベル: {常体/敬体/混合}
- 表現は簡潔にし、観察可能な言動を優先する

[Character Core]

{150~300トークン以内の人物核:

性格、対人姿勢、価値観、関係性、禁句、口調規則}

[Scene State]

{40~120トークン以内の現在地:

場所、直前出来事、感情、目的、未解決イベント}

[Post-History Instruction]

次の返答では:

- 2~5文で返す
- ユーザーへの質問は最大1個
- 既出情報の言い換え反復を避ける
- 必要なら短い動作描写を1つだけ入れる

Qwen3 を使うなら、**通常のロールプレイターンでは thinking を切るのが実務上かなり有効です**。公式モデルカードは `enable_thinking` の切替をサポートしており、HF の実運用 discussion でも `/think / / nothink / /no_think` を system か user に置く統合が案内されています。RP は数学推論ではないので、思考モードを切った方が遅延・メタ漏れ・テンポ悪化を避けやすいです。これはツール統合依存なので、使っているフロントエンドで有効な記法を確認してください。 ²²


Gemma 系は、**役割とターン区切りを壊さないことが最重要です**。フロントエンドや backend が `apply_chat_template` を持つなら自前で delimiter を手書きしない方が無難です。Gemma の instruction-tuned モデルは roles / turns を含む特定 formatter で学習されているからです。Gemma で壊れるときは、まず設定文章を増やすのではなく、**使っている chat template と system message の実送信内容を確認**する方が先です。ST も final prompt の inspection を勧めています。 ²⁴

逆に、よくないパターンは明確です。**一つの巨大 paragraph に人物史・世界史・喋り方・会話目標・禁止事項・関係図を全部詰める設計、否定命令を大量に並べる設計、サンプル会話だけに話し方保持を依存する設計、Narrator と character を同一ターンで兼務させる設計**です。ST の docs でも narrator を別キャラとして持つ発想が示されており、役割混線は避けるべきです。 ²⁵

English summary: The best prompt is not the longest prompt. Use a short permanent character core, place turn-control rules late in the prompt, keep scene-state separate, and only inject lore when needed. For Qwen3, disabling thinking for normal roleplay turns is often beneficial. For Gemma, never ignore the native role/turn formatting assumptions. ²⁶

会話維持のためのコンテキスト設計

会話維持では、「人格」「現在状態」「長期記憶」「世界知識」を別オブジェクトとして管理するのが正解です。ST の Main Prompt は通常最初、PHI は通常最後に入り、PHI は main prompt より高優先になり得ます。Author's Note は prompt 下部に近いほど次応答への効きが強く、World Info はキーワード発火の動的挿入です。Data Bank/RAG は chunk size、overlap、retrieved chunks、query messages、score threshold を制御できます。つまり、RP 用の最小構成は **恒常アンカー + 近接指示 + 動的 lore + 要約** です。 ²⁷



実務的には、次の分割が安定します。**恒常アンカー**にはキャラ核だけを置きます。**Scene State**には今の感情、目標、位置、直前イベントだけを置きます。**Summary Memory**には「誰が誰に何を言ったか」「未解決の伏線」「関係の変化」だけを圧縮します。**Lorebook/World Info**には百科事典的な情報を入れます。STの docs でも World Info は lore だけでなく memories や modular prompts に使えると明記されていますが、内容は concise に保つべきです。 28

要約は自動一本足打法にしない方がいいです。ST の summarizer docs は「古いメッセージが prompt から落ち始める時点」で要約更新を勧めていますが、コミュニティ実務では「長期RPでは手動 summary を scenario / AN / lorebook に入れるほうが信頼できる」という意見が繰り返し出ています。自動要約は便利ですが、主語混乱が致命傷なので、**人格情報は要約しない、出来事だけ要約するのが安全です。** 29

長期会話では、**章分け**が有効です。Reddit の実務知見では、会話を chapter 単位で構造化し、古いメッセージを hide して、重要点だけ summary として残す運用が推奨されています。これはSTの「履歴を全部保持しつつ、prompt には全部送らない」という設計と相性が良いです。長文ロールプレイで毎回全履歴を抱え込むのは非効率で、むしろ anchor の効力を落とします。 30

以下は、典型的な失敗例と改善例です。これは実在ログではなく、上記の失敗パターンを再現した**説明用の合成対話**です。背景にある失敗類型は、テンプレート不一致、ユーザー干渉、要約不備、反復です。 31

失敗例

User: 今日はどうしたの？

Model: こんにちは！私はあなたのお手伝いをするAIです。あなたは少し驚いた表情を浮かべながら私を見つめていますね。私は今、カフェであなたと楽しく会話していて、とても嬉しいです。今日はどうしましょうか？

問題は三つあります。**AI自己言及、ユーザー行動の代筆、キャラ固有口調の喪失**です。これは Main Prompt が弱いか、PHI/AN に turn-taking の制約がない時に起きやすいです。 11

改善例

User: 今日はどうしたの？

Model:別に。

少しだけ、あんたの顔を見に来ただけ。
それ以上の理由、今ここで必要？

この形は、**一人称・二人称・語尾・距離感・感情温度**を短く固定し、さらに「ユーザーの行動を書かない」「一歩だけ進める」を後段拘束したときに出やすくなります。 32

English summary: Treat persona, current scene, episodic memory, and lore as separate objects. Use a small permanent anchor, keep scene constraints near the end of the prompt, summarize only events, and chapter long sessions instead of feeding the entire history forever. 33

キャラクター性の評価法

「それっばい」で止めると改善できません。評価は最低でも **style・lexicon・emotion・factual consistency・persona adherence・turn control** の六軸で測るべきです。学術側では RoleLLM/RoleBench が role profile と role-specific knowledge injection を区別してベンチマーク化し、CharacterEval は 77 characters・1,785 multi-turn dialogues・13 metrics / 4 dimensions で Chinese role-play を包括評価しました。Persona 系研究も「consistent personality」が対話品質の主要課題だと扱っています。 34

また、日本語では **Japanese MT Bench** がかなり実用的です。SB Intuitions の説明では、Japanese MT Bench は English MT Bench のカテゴリ分けを踏襲し、Writing / Roleplay / Extraction / Reasoning / Math / Coding / STEM / Humanities の 8カテゴリで日本語の multi-turn dialogue 能力を測れます。llm-jp のモデルカードも Japanese MT Bench を用い、roleplay を独立カテゴリとして出しています。 35

以下は、ローカルRP向けに**再現しやすく数値化しやすい評価指標**へ落とした実務版です。これは CharacterEval や MT Bench の多面的発想を、アニメキャラRP運用へ寄せた合成指標です。 36

指標	何を見るか	取り方	合格目安の例	根拠
Persona Adherence Score	キャラらしさ総合	LLM-as-a-judge 1~5	4.0以上	37
Lexicon Hit Rate	口癖・語尾・一人称の維持	1000 tokens あたり一致数	安定して使用	6
Register Accuracy	敬体/常体/荒さ/丁寧さ	ルールベース点検	90%以上	38
User Agency Violation Rate	ユーザーの行動・心情を勝手に書く率	100ターン中の違反回数	0~2回以内	39
Self-Identity Contradiction Rate	自己認識や関係性の矛盾	summary/lore と照合	0件が理想	40
Scene-State Consistency	場所・時刻・直前出来事の整合	scene summary と照合	95%以上整合	41
Emotional Range Fit	喜怒哀楽の幅とキャラらしさ	judge 1~5	3.5以上	42
Repetition Severity	反復・言い換えループ	distinct-n / 繰返し span	連続反復なし	14
MT-Bench Roleplay Subscore	ベンチ上のRP能力	roleplayカテゴリ抜粋	比較表で監視	43

指標	何を見るか	取り方	合格目安 の例	根 拠
Latency / Throughput	体感速度	tok/s と返答開始遅延	用途次第	44

テストスイートは、**短期・中期・長期**の三段に分けると運用しやすいです。短期は 10~20 問の style regression。中期は 20 turn 前後で関係性と scene continuity を見る。長期は context overflow を跨ぐ 80~150 turn を回し、summary handoff 後も persona が残るかを見る。評価時はランダム性を減らす必要があるので、llama.cpp 系なら厳密比較時に greedy を `top_k=1` で作るのが安全です。 45

English summary: Measure roleplay like an engineering system, not like fandom intuition. Use a multidimensional scorecard: persona adherence, lexicon/register accuracy, user-agency violations, state contradictions, repetition, roleplay benchmark score, and latency. Run short, medium, and long-turn regression suites. 46

候補モデル比較

まず基準点です。**Gemma 3 1B IT** は Google の軽量オープンモデル群に属し、128K context、140+言語 support を持ち、ローカル展開しやすいサイズです。ただし、今回確認できた公式ソースでは、日本語ロールプレイ向けの明示的なベンチマークは見つかりませんでした。日本語RPを主目的にするなら、Gemma 3 1B は「ベースライン」にはなりますが、「最有力」ではありません。 47

次に、**Qwen 系は roleplay と multi-turn coherence の一次根拠が強い**です。Qwen2.5 は公式に system prompt 多様性への耐性向上と role-play 実装のしやすさを謳い、Qwen3 は creative writing ・ role-playing ・ multi-turn dialogues に優れると明記しています。しかも Qwen3-0.6B には公式の速度ベンチマークがあり、H20 96GB 環境で Transformers BF16 58.57 tok/s、SGLang 414.17 tok/s という値が公開されています。速度クラスだけ見れば、Gemma 3 1B より小さい 0.6B の Qwen3 は、少なくとも**同等以上に高速である可能性が高い**と見るのが合理的です。これは direct apples-to-apples 測定ではなく、サイズと公開ベンチマークに基づく推定です。 48

日本語中心なら、**Sarashina2.2-0.5B / 1B / 3B** は非常に重要です。SB Intuitions は 0.5B / 1B / 3B の instruct モデルを MIT ライセンスで公開し、Japanese MT Bench で 0.5B が 4.55、1B が 5.09、3B が 6.51 を出しています。特に 0.5B は Qwen2.5-0.5B の 2.95 より高く、1B も SB の評価条件では Qwen2.5-1.5B の 4.06 を上回っています。高速性の公式 tok/s は見つかりませんでした。0.5B と 1B というサイズから、Gemma 3 1B と同等~高速側の候補として扱う価値があります。 49

1.5B 級では、**TinySwallow-1.5B-Instruct** と **RakutenAI-2.0-mini-instruct** が面白いです。TinySwallow は Qwen2.5-1.5B 系を学生として日本語会話強化したモデルで、日本語 conversation 向けに instruction tuning されています。RakutenAI-2.0-mini-instruct は edge devices / low-latency / resource-constrained environments を明示し、日本語 MT-Bench 4.91 を報告しています。どちらも日本語RP候補としては有力ですが、速度は 1B 以下よりは落ちるはず。 50

一方で、**llm-jp-3-1.8b-instruct** は日本語研究基盤として有意義ですが、少なくともモデルカード掲載の Japanese MT Bench サブカテゴリでは roleplay が 2.60 と高くありません。RP専用という観点では、優先度は下がります。 51

モデル	サイズ	ライセンス	日本語の根拠	RP / coherence の根拠	速度の根拠	実務判断
Gemma 3 1B IT	1B	Gemma	140+ languages, 128K context ⁴⁷	公式ソースでは今回収集範囲に日本語RPベンチの明示なし ⁴⁷	直接比較できる公式 tok/s は今回未発見 ⁴⁷	ベースライン。日本語RP最優先なら第一候補ではない
Qwen3-0.6B	0.6B	Apache-2.0	100+ languages、強い multilingual instruction following ⁵²	creative writing / role-playing / multi-turn dialogues 改善を公式表明 ⁵³	H20 96GB: 58.57 tok/s (Transformers BF16), 414.17 tok/s (SGLang) ⁵⁴	速度最優先の本命
Qwen2.5-0.5B-Instruct	0.49B	Apache-2.0	29 languages incl. Japanese ⁵⁵	system prompt 多様性耐性、role-play 実装向上 ⁵⁶	A100 80GB: 49.94 tok/s (Transformers BF16), 270.49 tok/s (vLLM) ⁵⁷	超高速だがRP品質は弱め
Sarashina2.2-0.5B-Instruct	0.5B	MIT	Japanese-only。Japanese MT Bench 4.55 ⁵⁸	SB 比較で Qwen2.5-0.5B より高得点 ⁵⁹	公式 tok/s 未発見。サイズ上は高速側と推定 ⁶⁰	日本語超小型の本命
Sarashina2.2-1B-Instruct	1B	MIT	Japanese-only。Japanese MT Bench 5.09 ⁶¹	SB 比較では安定して高性能、日英両立と評価 ⁵⁹	公式 tok/s 未発見。Gemma 3 1B と同サイズ帯 ⁶²	1B 級で日本語最有力
RakutenAI-2.0-mini-instruct	1.5B	Apache-2.0	Japanese + English、edge / low-latency 明記 ⁶³	Japanese MT-Bench 4.91 ⁶³	公式 tok/s 未発見	エッジ重視の有力候補


モデル	サイズ	ライセンス	日本語の根拠	RP / coherence の根拠	速度の根拠	実務判断
TinySwallow-1.5B-Instruct	1.5B	Apache-2.0 + Gemma terms	Japanese、会話強化用 途明記 ⁶⁴	SB 比較で Japanese MT Bench 5.24、Qwen2.5-1.5B 学生系 ⁶⁵	公式 tok/s 未発見。 Qwen2.5-1.5B 系と近い速度クラスと推定 ⁶⁴	日本語 RP 寄りの強い候補
Qwen2.5-1.5B-Instruct	1.54B	Apache-2.0	29 languages incl. Japanese ⁶⁶	role-play 実装しやすさ、system prompt 耐性 ⁶⁷	A100 80GB: 40.89 tok/s (Transformers BF16), 175.55 tok/s (vLLM) ⁶⁸	総合バランスが良い
llm-jp-3-1.8b-instruct	1.8B	Apache-2.0	Japanese + English ⁵¹	Japanese MT Bench の roleplay 2.60、平均 4.93 ⁵¹	公式 tok/s 未発見	RP 専用なら優先度低め

用途別に絞ると、**最速候補**は Qwen3-0.6B と Sarashina2.2-0.5B、**日本語RPの現実解**は Sarashina2.2-1B、**少し遅くても安定性を取りたい**なら TinySwallow-1.5B と Qwen2.5-1.5B です。Gemma 3 1B を使い続ける理由があるなら、まずモデル変更よりも prompt/context 設計と template 整合を処置してください。そこを直さずモデルだけ変えても、同じ壊れ方をします。 ⁶⁹

English summary: The strongest small local bets for Japanese roleplay are Qwen3-0.6B if speed dominates, Sarashina2.2-1B if Japanese fidelity dominates, and Qwen2.5-1.5B / TinySwallow-1.5B if you can afford slightly more latency for better stability. Gemma 3 1B is a useful baseline but not the clearest Japanese-RP winner in the reviewed sources. ⁷⁰

改善手順とサンプル集

改善は、**モデル変更より prompt inspection が先**です。ST の docs は final prompt を確認することを強く勧めています。そこで「本当に何が送られているか」を見て、テンプレート不一致、恒常トークン過多、PHI 欠落、Lorebook の不発を潰します。これが first pass です。 ⁷¹



実践手順は次の順で十分です。**手順一**、chat template をモデルに合わせます。Gemma / Qwen と frontend の組み合わせで template mismatch がないか確認します。**手順二**、人物核を 150~300 token 程度へ圧縮します。**手順三**、今このターンだけ効かせたいルールを PHI/AN へ移します。**手順四**、出来事要約を 6~12 ターンごと、または古い履歴が落ち始める時点で更新します。**手順五**、Lorebook は standalone 短文で書き、長文資料は RAG chunking へ回します。**手順六**、Qwen3 なら non-thinking、反復が出るなら `presence_penalty=1.5`、llama.cpp なら repeat penalty / DRY を調整します。**手順七**、固定テストセットで回帰確認します。ここまでやってから、まだ壊れるならモデルを 0.5B→1B→1.5B と段階的に上げます。 72

以下は、**失敗モード別の即効パッチ**です。いずれも上記ソース群を踏まえた合成テンプレートです。 73

失敗モード	追加する短文	生成設定パッチ	備考
ユーザーの台詞まで書く	<code>{{char}}</code> は <code>{{user}}</code> の台詞・行動・内心を書かない。	<code>max_new_tokens</code> を下げる	後段に置くと効きやすい 74
すぐAI口調へ戻る	AIとしてではなく <code>{{char}}</code> としてのみ返答する。	<code>do_sample</code> を弱める	例文依存をやめて恒常アンカー化 75
感情が平板	現在の感情温度: {0-5} 返答に感情の痕跡を一つ入れる	温度を少し上げる	Scene State に置く 76
反復ループ	同じ言い回しを繰り返さない	Qwen3: <code>presence_penalty=1.5</code> ; llama.cpp: repeat / DRY	長文化も止める 77

失敗モード	追加する短文	生成設定パッチ	備考
設定忘れ	重要既知事実: 以下を短い箇条書き化	summary 更新	例文や first message 依存をやる ⁷⁸
思考漏れ / メタ解説	直接答える。思考過程を出さない。	Qwen3: non-thinking	integration 依存 ²²

サンプルプロンプト A: 小型モデル用の最小構成

System:
 あなたは綾波レイ型の寡黙な少女キャラクターである。
 AIとして説明しない。常に日本語で、短く、感情を抑えた返答をする。
 一人称は「私」。二人称は「あなた」。
 語尾は断定的すぎず、平坦にする。
 ユーザーの台詞・行動・内心を書かない。
 同じ語句を繰り返さない。

Character Core:

- 無口
- 必要以上に喋らない
- 好意は露骨に出さない
- 返答は2〜4文
- 矛盾したら直前の scene state を優先

Scene State:

- 放課後の教室
- 直前にユーザーが「疲れた」と言った
- 少し気にしているが露骨には心配しない

PHI:
 次の返答では、短い労りを示しつつ、場面を一步だけ進める。

このテンプレートは、恒常部分を短くし、シーン固有情報だけを別枠にした点が重要です。Persona-Chat / Persona-based dialogue 研究が指摘した「一貫性」の問題と、ST の恒常/非恒常トークン設計の両方に沿っています。 ⁷⁹

サンプルプロンプト B: Qwen3 低遅延RP

System:
 You are {char_name}. Stay fully in character. Reply only in Japanese.
 /no_think

Rules:

- Never write the user's dialogue, actions, or thoughts.
- No meta commentary.
- Keep replies under 5 sentences.

- Preserve speech style markers: {markers}
- Advance the scene by one beat only.

Qwen3 は thinking / non-thinking の切替を持ち、role-playing 改善を打ち出しているため、通常RPではこちらの方が扱いやすいです。Qwen3 で反復が出たら `presence_penalty=1.5` を試してください。 ²²

サンプルプロンプト C: Lorebook 用の記述形式

Key: 学生会長, 生徒会, 会長室

Content:

{char_name} は学園の生徒会長である。

外面は冷静で統制的だが、親しい相手にはやや過保護になる。

公的な場では敬語を使うが、二人きりでは敬語が少し崩れる。

World Info では key や title そのものは model に入らず、content が standalone である必要があります。Lorebook を「見出しだけ立派なメモ」にはしてはいけません。 ¹³

最後に、改善の優先順位だけ明確にします。**最初にやるべきことは、モデル変更ではなく prompt/context 分離の実装です。** そのうえでモデルを替えるなら、速度重視は Qwen3-0.6B、JP重視は Sarashina2.2-1B、総合安定は Qwen2.5-1.5B か TinySwallow-1.5B が現時点の合理的選択です。 ⁸⁰

English summary: Fix the prompt stack before changing the model. Inspect the actual final prompt, compress permanent persona, move short-turn rules late in the prompt, maintain a rolling event summary, inject lore dynamically, tune anti-repetition settings, and only then scale up the model. For fast Japanese local RP, the most practical escalation path is Qwen3-0.6B → Sarashina2.2-1B → Qwen2.5-1.5B / TinySwallow-1.5B. ⁸¹

¹ <https://aclanthology.org/P16-1094/>

<https://aclanthology.org/P16-1094/>

² ⁷ ²³ ²⁴ <https://ai.google.dev/gemma/docs/core/prompt-structure>

<https://ai.google.dev/gemma/docs/core/prompt-structure>

³ ⁴⁷ <https://huggingface.co/google/gemma-3-1b-it>

<https://huggingface.co/google/gemma-3-1b-it>

⁴ ³⁶ ³⁷ ⁴² ⁴⁶ <https://aclanthology.org/2024.acl-long.638/>

<https://aclanthology.org/2024.acl-long.638/>

⁵ ¹⁶ ³¹ ⁷² https://qwen.readthedocs.io/en/latest/getting_started/concepts.html

https://qwen.readthedocs.io/en/latest/getting_started/concepts.html

⁶ ³⁸ ⁷⁹ <https://aclanthology.org/P18-1205/>

<https://aclanthology.org/P18-1205/>

⁸ ¹³ ⁴⁰ <https://docs.sillytavern.app/usage/core-concepts/worldinfo/>

<https://docs.sillytavern.app/usage/core-concepts/worldinfo/>

⁹ ¹⁴ <https://github.com/ggml-org/llama.cpp/blob/master/tools/completion/README.md>

<https://github.com/ggml-org/llama.cpp/blob/master/tools/completion/README.md>

10 12 21 75 78 <https://docs.sillytavern.app/usage/core-concepts/characterdesign/>
<https://docs.sillytavern.app/usage/core-concepts/characterdesign/>

11 18 19 25 26 27 28 32 33 39 71 73 74 81 <https://docs.sillytavern.app/usage/prompts/>
<https://docs.sillytavern.app/usage/prompts/>

15 <https://github.com/ggml-org/llama.cpp/issues/1647>
<https://github.com/ggml-org/llama.cpp/issues/1647>

17 48 56 67 <https://qwenlm.github.io/blog/qwen2.5/>
<https://qwenlm.github.io/blog/qwen2.5/>

20 76 <https://docs.sillytavern.app/usage/core-concepts/authors-note/>
<https://docs.sillytavern.app/usage/core-concepts/authors-note/>

22 52 53 69 70 77 80 <https://huggingface.co/Qwen/Qwen3-0.6B>
<https://huggingface.co/Qwen/Qwen3-0.6B>

29 41 <https://docs.sillytavern.app/extensions/summarize/>
<https://docs.sillytavern.app/extensions/summarize/>

30 https://www.reddit.com/r/SillyTavernAI/comments/1m4isim/just_a_tip_on_how_to_structure_and_deal_with_long/
https://www.reddit.com/r/SillyTavernAI/comments/1m4isim/just_a_tip_on_how_to_structure_and_deal_with_long/

34 <https://arxiv.org/abs/2310.00746>
<https://arxiv.org/abs/2310.00746>

35 49 59 65 <https://www.sbintuitions.co.jp/blog/entry/2025/03/07/093143>
<https://www.sbintuitions.co.jp/blog/entry/2025/03/07/093143>

43 51 <https://huggingface.co/llm-jp/llm-jp-3-1.8b-instruct>
<https://huggingface.co/llm-jp/llm-jp-3-1.8b-instruct>

44 54 https://qwen.readthedocs.io/en/latest/getting_started/speed_benchmark.html
https://qwen.readthedocs.io/en/latest/getting_started/speed_benchmark.html

45 <https://github.com/ggml-org/llama.cpp/discussions/3005>
<https://github.com/ggml-org/llama.cpp/discussions/3005>

50 64 <https://huggingface.co/SakanaAI/TinySwallow-1.5B-Instruct>
<https://huggingface.co/SakanaAI/TinySwallow-1.5B-Instruct>

55 <https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct>
<https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct>

57 68 https://qwen.readthedocs.io/en/v2.0/benchmark/speed_benchmark.html
https://qwen.readthedocs.io/en/v2.0/benchmark/speed_benchmark.html

58 60 <https://huggingface.co/sbintuitions/sarashina2.2-0.5b-instruct-v0.1>
<https://huggingface.co/sbintuitions/sarashina2.2-0.5b-instruct-v0.1>

61 62 <https://huggingface.co/sbintuitions/sarashina2.2-1b-instruct-v0.1>
<https://huggingface.co/sbintuitions/sarashina2.2-1b-instruct-v0.1>

63 <https://huggingface.co/Rakuten/RakutenAI-2.0-mini-instruct>
<https://huggingface.co/Rakuten/RakutenAI-2.0-mini-instruct>

66 <https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>
<https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>